

Actividad de Modelos Lineales Generalizados (GLM)

Daniel Arteta Salazar

2025-11-08

Contents

Resumen	2
1. Datos y variables	3
1.1. Importar librerías	3
1.2. Preparación de los datos	3
1.3. Resumen de la sección	4
2. Análisis descriptivo	4
2.1. Análisis univariado	4
2.2. Análisis bivariado	9
3. Correlaciones y relaciones clave	9
4. Modelado GLM (frecuencia y severidad)	9
5. Prima pura por segmentos	9
6. Recomendaciones tarifarias	9
7. Limitaciones del análisis	9

Resumen

1. Datos y variables

1.1. Importar librerías

```
library(readxl)
library(tidyverse)
library(ggplot2)
```

1.2. Preparación de los datos

```
# Importar base de datos
base <- read_excel("../datos/base_seguro_15000.xlsx")

# Adecuar el nombre de las variables
base <- base %>% janitor::clean_names()

# Tamaño de la tabla
dim(base)

## [1] 15000      7

# Resumen de las variables
summary(base)

##      edad          sexo          tipo          region      
##  Min.   :18.00    Length:15000    Length:15000    Length:15000  
##  1st Qu.:33.00   Class :character  Class :character  Class :character  
##  Median :49.00   Mode   :character  Mode   :character  Mode   :character  
##  Mean   :49.07                                                        
##  3rd Qu.:65.00                                                        
##  Max.   :80.00                                                        
##      reclamos       costo Esperado      prima_pura      
##  Min.   :0.00000    Min.   : 26.18    Min.   :     0.0  
##  1st Qu.:0.00000   1st Qu.:1929.99  1st Qu.:     0.0  
##  Median :0.00000   Median :3660.01   Median :     0.0  
##  Mean   :0.03433   Mean   :4940.43   Mean   :  203.6  
##  3rd Qu.:0.00000   3rd Qu.:6375.56  3rd Qu.:     0.0  
##  Max.   :2.00000   Max.   :46043.90  Max.   :38720.5 

# Registros duplicados
sum(duplicated(base))

## [1] 0

# Número de valores nulos por variable
colSums(is.na(base))

##      edad          sexo          tipo          region      reclamos      
## 0          0          0          0          0          0          0          

# Agregamos una variable categórica por edad
base$grupo_etario <- cut(base$edad,
                           breaks = c(0, 10, 20, 30, 40, 50, 60, 70, 80, 90, 100),
                           labels = c("1-10", "11-20", "21-30", "31-40", "41-50",
                                     "51-60", "61-70", "71-80", "81-90", "91-100"),
```

```
right = TRUE)
```

1.3. Resumen de la sección

No se encuentran valores anormales en las variables, registros duplicados ni valores nulos, por lo que no se realiza ninguna modificación a los datos.

2. Análisis descriptivo


2.1. Análisis univariado

2.1.1. Edad

```
summary(base$edad)
```

```
##      Min. 1st Qu. Median      Mean 3rd Qu.      Max. 
##     18.00   33.00   49.00   49.07   65.00   80.00 

ggplot(base, aes(x = edad)) + 
  geom_histogram(binwidth = 10, fill = "steelblue", color = "white", alpha = 0.7) + 
  labs(title = "Distribución de Edades por Decenas",
       x = "Edad",
       y = "Frecuencia") + 
  theme_minimal()
```




2.1.1. Sexo

```
# Tabla de frecuencia
base %>%
  count(sexo) %>%
  mutate(
    proporcion = n / sum(n),
    porcentaje = proporcion * 100
  ) %>%
  rename(frecuencia = n)

## # A tibble: 2 x 4
##   sexo   frecuencia proporcion porcentaje
##   <chr>     <int>      <dbl>      <dbl>
## 1 F          7841      0.523      52.3
## 2 M          7159      0.477      47.7

# Gráfico de barras
ggplot(base, aes(x = sexo)) +
  geom_bar()
```



2.1.2. Tipo

```
# Tabla de frecuencia
base %>%
  count(tipo) %>%
  mutate(
    proporcion = n / sum(n),
```


```

    porcentaje = proporcion * 100
) %>%
rename(frecuencia = n)

## # A tibble: 2 x 4
##   tipo     frecuencia proporcion porcentaje
##   <chr>     <int>      <dbl>      <dbl>
## 1 Básico     10462      0.697     69.7
## 2 Premium     4538       0.303     30.3

# Gráfico de barras
ggplot(base, aes(x = tipo)) +
  geom_bar()

```



2.1.3. Región

```

# Tabla de frecuencia
base %>%
  count(region) %>%
  mutate(
    proporcion = n / sum(n),
    porcentaje = proporcion * 100
) %>%
  rename(frecuencia = n)

## # A tibble: 5 x 4
##   region     frecuencia proporcion porcentaje
##   <chr>     <int>      <dbl>      <dbl>
## 1 Centro      10000      0.697     69.7
## 2 Noreste     30000      0.303     30.3
## 3 Noroeste     5000      0.0500    5.00
## 4 Sur         10000      0.0500    5.00
## 5 Sudeste      5000      0.0500    5.00

```

```


## 1 Centro      4501      0.300      30.0
## 2 Norte       2948      0.197      19.7
## 3 Occidente   2302      0.153      15.3
## 4 Oriente     2242      0.149      14.9
## 5 Sur         3007      0.200      20.0

```

```

# Gráfico de barras
ggplot(base, aes(x = region)) +
  geom_bar()

```




2.1.3. Reclamo

```

# Tabla de frecuencia
base %>%
  count(reclamos) %>%
  mutate(
    proporcion = n / sum(n),
    porcentaje = proporcion * 100
  ) %>%
  rename(frecuencia = n)

## # A tibble: 3 x 4
##   reclamos frecuencia proporcion porcentaje
##       <dbl>      <int>      <dbl>      <dbl>
## 1          0        14499    0.967     96.7
## 2          1         487    0.0325     3.25
## 3          2          14    0.000933  0.0933

```



2.1.4. Costo esperado


```
summary(base$costo Esperado)

##      Min.    1st Qu.     Median      Mean    3rd Qu.      Max.
##  26.18   1929.99   3660.01   4940.43   6375.56  46043.90

ggplot(base, aes(x = "", y = costo Esperado)) +
  geom_violin(fill = "lightblue", color = "darkblue", alpha = 0.7, trim = FALSE) +
  geom_boxplot(width = 0.1, fill = "white", alpha = 0.5, outlier.color = "red") +
  labs(title = "Distribución del Costo Esperado - Violín Plot",
       subtitle = "Combinación de violín + boxplot",
       y = "Costo Esperado ($)",
       x = "") +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"),
        plot.subtitle = element_text(hjust = 0.5))
```

Distribución del Costo Esperado – Violín Plot

Combinación de violín + boxplot



2.2. Análisis bivariado

2.2.1. Costo esperado

2.2.2. Costo esperado

2.2.3. Costo esperado

2.2.4. Costo esperado

3. Correlaciones y relaciones clave

4. Modelado GLM (frecuencia y severidad)

5. Prima pura por segmentos

6. Recomendaciones tarifarias

7. Limitaciones del análisis